DOI:10.13196/j.cims.2022.07.018

联邦学习概述:技术、应用及未来

李少波[1,2],杨 磊[2+],李传江[2],张安思[1,2],罗瑞士[2]
(1.贵州大学 省部共建公共大数据国家重点实验室,贵州 贵阳 550025;
2.贵州大学 机械工程学院,贵州 贵阳 550025)

摘 要:联邦学习(FL)以多方数据参与为驱动,通过数据加密交互实现数据自身价值的最大化,近年来受到各界研究学者的广泛关注与研究,逐步从基础理论研究走向实际应用,为企业进一步发挥数据价值提供了新技术。在阐述联邦学习定义及分类的基础上,首先对其隐私保护、通信效率、异构性、激励机制等相关技术的国内外研究进展展开了较为全面的分析和总结;其次介绍了当前联邦学习已有的应用平台和框架,并提出了联邦学习在智能制造、医疗、教育等领域的应用框架;最后,结合联邦学习在一些关键的开放性问题上的不足,对其未来发展趋势和方向进行了总结与展望,旨在为联邦学习的理论研究及应用落地提供参考。

关键词:联邦学习;隐私保护;通信效率;异构性;激励机制
中图分类号:TP309;TP181 **文献标识码**:A

Overview of federated learning: Technology, applications and future

LI Shaobo[1,2], *YANG Lei*[2+], *LI Chuanjiang*[2], *ZHANG Ansi*[1,2], *LUO Ruishi*[2]
(1. State Key Laboratory of Public Big Data, Guizhou University, Guiyang 550025, China;
2. School of Mechanical Engineering, Guizhou University, Guiyang 550025, China)

Abstract: Federated Learning (FL) is driven by multi-party data participation, and it maximizes the value of the data itself through data encryption interaction. In recent years, FL has attracted extensive attention from researchers from all walks of life and gradually moved from basic theoretical research to practical applications, which provides new technologies for further exploiting the value of data for enterprises. Based on the definition and classification of FL, a comprehensive analysis and summary of the research progress of related technologies at home and abroad was conducted, including privacy protection, communication efficiency, heterogeneity, and incentive mechanisms. The current application platforms and frameworks of FL were introduced, and the application frameworks of FL was proposed in the fields of intelligent manufacturing, medical treatment and education. Combined with the deficiencies of FL in some key open issues, its future development trends and directions were summarized for providing a reference for the theoretical research and applications of FL.

Keywords: federated learning; privacy protection; communication efficiency; heterogeneity; incentive mechanism

收稿日期:2021-06-07;**修订日期**:2021-08-07。Received 07 June 2021;accepted 07 Aug. 2021.
基金项目:国家重点研发计划资助项目(2020YFB1713300);贵州省高等学校人才培养基地资助项目(黔教合 KY 字[2020]009);贵州省科技计划资助项目(黔科合人才[2015]4011、黔科合平台人才[2017]5788);贵州省重大科技专项计划资助项目(黔科合重大专项字[2019]3003);贵州省高等学校集成攻关大平台资助项目(黔教合 KY 字[2020]005)。**Foundation items**: Project supported by the National Key Research and Development Program, China (No. 2020YFB1713300), the Guizhou Provincial Colleges and Universities Talent Training Base, China (No. QJH KY[2020]009), the Guizhou Provincial Science and Technology Plan, China (No. QKHT[2015]4011, QKHPT[2017]5788), the Guizhou Provincial Major Science and Technology Special Program, China (No. QKH Major Special Project[2019]3003), and the Guizhou Provincial Higher Education Integrated Research Platform, China (No. QJH KY[2020]005).

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

1 问题的描述

随着第四次工业革命的到来，新一代人工智能、大数据等技术为传统行业智能化转型发展带来了机遇，如制造行业已由传统制造模式升级为数据驱动下的智能制造[1-2]，其中以铸造行业、船舶以及汽车等行业为典型；与此同时，在数据成为生产要素并发挥着愈加重要作用的今天，也对数据共享及隐私安全提出了新挑战。由于行业间的竞争、垄断以及不同企业之间业务的封闭性和阻塞性，使得企业之间数据信息交互困难重重。

机器学习（Machine Learning，ML）作为近年来大数据分析的主要方法之一[3-4]，涵盖了支持向量机[5-6]、神经网络[7-8]、聚类算法[9-10]、回归算法[11-12]等多种智能算法，在诸多领域的应用效果已超过人类表现[13]，成功应用于医疗卫生[14]、财务管理[15]以及工业制造[16]等领域。传统的机器学习方法是基于所有数据集中训练[17]，但存在以下限制：①企业之间受限于某些商业因素[18]，难以实现数据的充分共享[19]，存在严重的数据孤岛现象；②在传统的机器学习过程中，数据传输至企业服务器的过程中存在隐私泄露风险，或者云端集中式训练数据模型可能会将其暴露给恶意攻击者；③集中式训练数据模型对企业服务器的计算和存储能力带来了巨大的挑战。

为解决以上问题，谷歌[20]于 2016 年首次提出联邦学习（Federated Learning，FL）理论。作为机器学习的新兴范式，联邦学习为用户数据共享提供了新颖的解决方案，使得用户原始数据在不出本地的基础上便能得到一个更优化的模型，做到“数据不动模型动”，在保证用户数据隐私安全的前提下，打破数据孤岛，充分挖掘数据中的潜在价值。目前，联邦学习已初步应用于医学成像[21]、智能终端[22]以及计算机视觉[23]等领域。

通过调研近 3 年的联邦学习综述文献，联邦学习的隐私安全、应用和其他（如通信开销、激励机制等）3 个方面，各占文献总数的 43.75%、31.25%、25%，如图 1 所示。表 1 列出了 2019～2021 年部分联邦学习综述文献，如 MOTHUKURI 等[24]全面介绍了当前联邦学习面临的安全威胁及应对策略；LI 等[25]在介绍了联邦学习模型训练时可能受到相关攻击的基础上，介绍了其在移动设备、医疗、工业等方面的应用；KULKARNI 等[26]从多任务学习、元学习等方面介绍了联邦学习中针对异构性问题的相关技术研究进展。可以看出，近年来，领域学者主要聚焦于联邦学习的隐私安全、通信、异构性或者激励机制等单方面的综述，缺少全面系统性的综述研究。为此，本文围绕联邦学习的技术、应用以及未来方向 3 个方面，进行了较为全面的分析和总结。

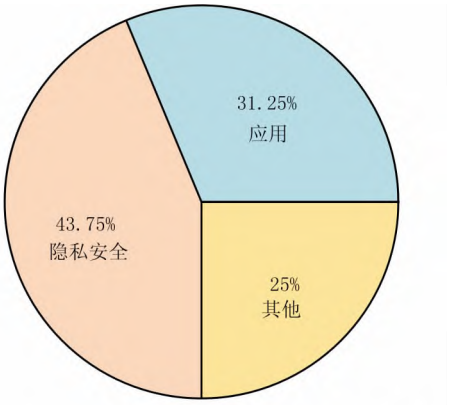


图1 2019～2021年联邦学习综述文献的分析角度分布图

表 1 2019～2021 年部分综述文献

综述内容	作者	年份	文献名称
隐私安全威胁、防御策略	MOTHUKURI 等[24]	2021	A survey on security and privacy of federated learning
工业、移动设备、医疗	LI 等[25]	2020	A review of applications in federated learning
个性化技术	KULKARNI 等[26]	2020	Survey of personalization techniques for federated learning
应用、通信、异构性、攻击方式	MAMMEN[27]	2021	Federated learning：Opportunities and challenges
隐私安全、异构性	ZHANG 等[28]	2021	A survey on federated learning
通信开销	邱鑫源[29]	2021	联邦学习通信开销研究综述
激励机制	ZHAN 等[30]	2021	A Survey of incentive mechanism design for federated learning
统计和系统异构性、隐私安全、医疗	XU 等[31]	2021	Federated learning for healthcare informatics
隐私安全、攻击方式、防御策略	BLANCO-JUSTICIA 等[32]	2020	Achieving security and privacy in federated learning systems：Survey，research challenges and future directions

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

续表 1

攻击方式、防御策略	LYU 等[33]	2020	Privacy and robustness in federated learning:Attacks and defenses
隐私安全威胁、防御策略	陈兵等[34]	2020	联邦学习安全与隐私保护综述
通信、资源分配、隐私安全	LIM 等[35]	2020	Federated learning in mobile edge networks:A comprehensive survey
隐私安全、医学成像	KAISSIS 等[36]	2020	Secure, privacy-preserving and federated machine learning in medical imaging
回顾分布式机器学习在医疗中应用	ZERKA 等[37]	2020	Systematic review of privacy-preserving distributed machine learning from federated databases in health care
隐私安全、激励机制	YANG 等[38]	2020	Federated learning:Privacy and incentive
相关协议、平台和应用	ALEDHARI 等[39]	2020	Federated learning: A Survey on enabling technologies, protocols, and applications
通信效率、异构性、隐私保护、物联网	BRIGGS 等[40]	2020	A review of privacy preserving federated learning for private IoT analytics
定义、架构和应用	YANG 等[19]	2019	Federated machine learning:Concept and applications
通信、异构、隐私保护	LI 等[41]	2019	Federated learning:Challenges, methods, and future directions

注:文献来源:Web of Science、谷歌学术、中国知网。

2　联邦学习基本概念

2.1　联邦学习的定义

联邦学习又称为联邦机器学习、联合学习或联盟学习,是一种新型的机器学习框架,包含对等网络结构[42]和用户—服务器[43]两种联邦学习架构,后者应用居多,其架构学习流程及模型训练步骤分别如图 2 和表 2 所示。由于在实际生活中,企业和用户数据大都以分散的形式存在,而联邦学习作为应对数据孤岛问题的有效解决方案,在满足用户数据隐私安全和政府相关法规的前提下,对多个数据拥有方进行联合建模,且不需要共享各用户的原始数据,即联邦学习面向的对象是分散式多用户的场景。设有 N 位用户参与 $\{F_1, F_2, F_3, \cdots, F_N\}$,其本地数据集为 $\{D_1, D_2, D_3, \cdots, D_N\}$,联邦学习允许参与者协同训练出一个共同的共享模型 $\{M_{FED}\}$,而传统机器学习是将数据集中进行模型 $\{M_{SUM}\}$ 的训练,设 $\{V_{FED}\}$ 和 $\{V_{SUM}\}$ 分别表示 $\{M_{FED}\}$,$\{M_{SUM}\}$ 的模型精度,存在一个正数 δ,满足:

$$|V_{FED} - V_{SUM}| < \delta。 \tag{1}$$

则称其在联邦学习模型允许的性能损失范围内达到了 δ-精度损失[19]。

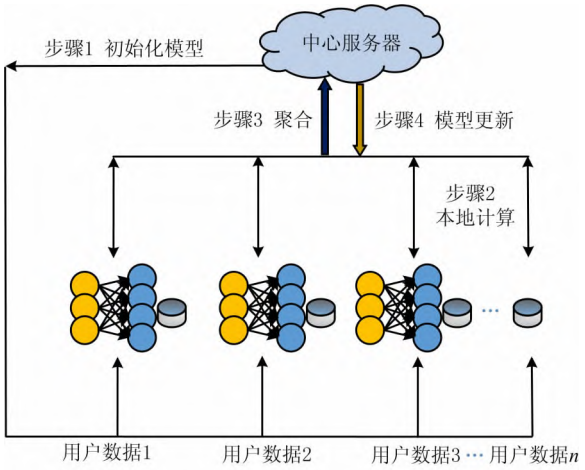


图2　用户—服务器学习流程

表 2　用户—服务器模型训练步骤

用户—服务器架构:模型训练共包括以下 4 个步骤。
步骤 1　本地用户从中心服务器下载初始化全局模型。
步骤 2　各用户利用初始化全局模型进行本地计算,称为局部模型训练。
步骤 3　本地模型训练后将更新的模型和参数上传给中央服务器。
步骤 4　中央服务器对各用户传来的模型和参数进行聚合后,用于新一轮的更新,常用的聚合方法是联邦平均(Federated Averaging, FedAvg)[20]算法。
联邦学习处于持续迭代过程,重复步骤 2 和步骤 3,直至本地模型达到理想收敛效果。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

2.2 联邦学习的分类

根据参与用户数据的样本及其特征之间的差异性，联邦学习可分为横向联邦学习（Horizontal Federated Learning，HFL）[44]、纵向联邦学习（Vertical Federated Learning，VFL）[45]和联邦迁移学习（Federated Transfer Learning，FTL）[46-47]，如图 3 所示。因此，可根据数据孤岛的不同分布特点，提供不同的联邦学习方案。

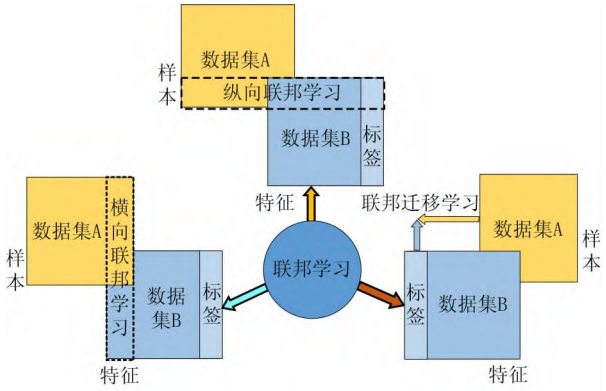


图3 联邦学习分类

横向联邦学习适用于用户数据的特征重叠较多而其样本重叠较少的情况，即按样本划分[48]。设有 A、B 两个用户，(D_i, D_j)、(X_i, X_j)、(L_i, L_j)分别为用户 A 和用户 B 的数据、特征空间、数据标签和样本 ID 空间，即：

$$X_i = X_j, L_i = L_j, I_i \neq I_j, \forall D_i, D_j, i \neq j。(2)$$

与横向联邦学习不同的是，纵向联邦学习适用于用户数据的特征重叠较少而其样本重叠较多的场景，即按特征划分[48]：

$$X_i = X_j, L_i \neq L_j, I_i = I_j, \forall D_i, D_j, i \neq j。(3)$$

联邦迁移学习则适用于用户数据的样本和特征都没有重叠或者重叠较少的情况，即某些用户可能只有数据而没有或者仅有很少的数据标签，即：

$$X_i \neq X_j, L_i \neq L_j, I_i \neq I_j, \forall D_i, D_j, i \neq j。(4)$$

3 联邦学习技术研究进展

联邦学习作为连接数据孤岛的桥梁，在满足数据隐私安全和监管要求的前提下，使各用户有效地利用其本地模型参数获得高质量的联邦学习模型。但随着联邦学习的发展，也暴露了其存在的诸多问题，如模型训练存在的潜在威胁、通信效率慢、用户数据可用性差、设备的不稳定性以及参与用户处于不公平地位等。因此，需权衡联邦学习中的隐私安全、通信效率、异构性以及公平性等多方面因素，如采用安全多方计算、模型压缩、知识蒸馏、博弈论等技术，来构建一个更加安全、有效、公平的联邦学习模型，如图 4 所示。为此，本章将从联邦学习的隐私保护、通信效率、异构性、激励机制 4 个方面，依次对其相关技术展开较为全面的综述。

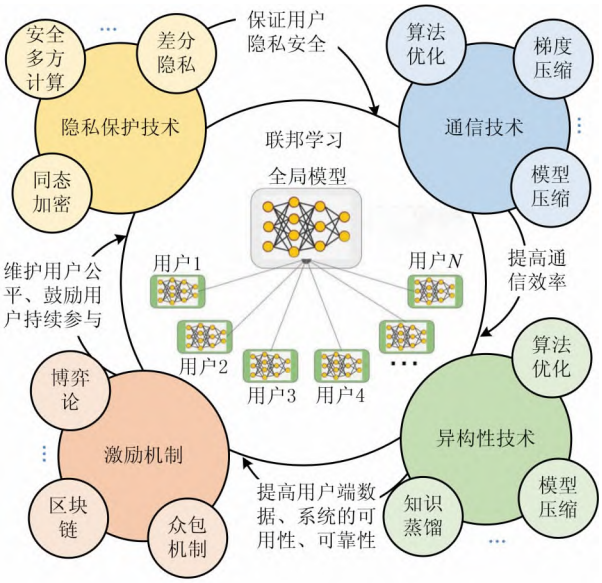


图4 安全、有效、公平的联邦学习模型

3.1 隐私保护

隐私保护是指对个人或企业敏感信息进行保护的措施。因联邦学习是建立在分布式训练用户本地数据的基础上，利用边缘端或用户端设备协同构建一个共享的联邦学习模型。但其用户本地数据可能包含如企业的客户资料、业务数据等企业敏感信息，关乎着企业声誉、公众信任感、经济利益等重大问题，一旦泄露将造成不可挽回的巨大损失。尽管在联邦学习模型训练过程中，各用户本地原始数据并未公开，但其局限性在于，若存在“不诚实”、“诚实且好奇”的服务器或者恶意用户端，用户本地数据信息仍可能从更新后的模型参数中被反推出来，即推理攻击，以及投毒攻击、基于生成式对抗网络（Generative Adversarial Networks，GAN）的攻击等其他多种类型攻击，对联邦学习的隐私安全造成了巨大的潜在威胁，因而现阶段联邦学习尚未获得广泛信任。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

为此,本节主要介绍目前联邦学习中如安全多方计算、同态加密、差分隐私等主流的隐私保护技术及其相关研究进展。

(1)安全多方计算

1982 年 YAO[49]针对“百万富翁问题”提出安全多方计算并得到广泛应用,其原理是在仅展示用户输出信息的基础上,使参与者能够协同地从各参与方隐私输入数据中计算相关函数,并保证参与者输入信息不被泄露。设 n 个参与者共同分配某个私有数值 x,每个参与者 P_i 根据其拥有的内容 x_i 协同计算,得到相应的输出信息 y_i,即

$$y_1, y_2, \cdots, y_n = f(x_1, x_2, \cdots, x_n)。\tag{5}$$

(2)同态加密

同态加密是 RIVEST 等[50]于 1978 年提出,考虑到参与方存在“恶意”或“诚实且好奇”的情形,采用加密方法对数据传输过程进行保护,是防御隐私攻击的有效措施。其特性在于可对密文解密后得到明文结果,而不需要直接访问明文。设 H 为一个同态加密方法,则有

$$H = \{KeyGen, Enc, Dec, Eval\}。\tag{6}$$

式中:$KeyGen$ 为密匙生成函数,Enc 为加密函数,Dec 为解密函数,$Eval$ 为评估函数。不同于安全多方计算,同态加密允许在加密内容上进行某些特定的代数运算,如加法和乘法[51],以加性同态加密为例,其定义如下:

$$Enc_{pk}(m_1) = c_1, Enc_{pk}(m_2) = c_2。\tag{7}$$

$$Dec_{sk}(c_1 \circ c_2) = m_1 + m_2。\tag{8}$$

式中:pk、sk 分别是公钥和私钥,c_1、c_2 分别是对明文 m_1、m_2 的加密结果,$\circ$是某种加法或乘法运算。

(3)差分隐私

差分隐私[52]则是将随机生成的噪声添加到基础数据库中,使数据库中的个体信息混淆,达到敌手无法从查询结果中获取个体敏感信息的目的。其安全性能被广泛认为是当前基于扰动的隐私保护技术中最高的[53]。设两个数据集 D 和 D' 且只有一个记录不同,M 为随机保护机制,S 为任意可能的输出,且 $S \subset Range(M)$,对于$(\in, \delta)$有:

$$Pr[M(D) \in S] \leqslant Pr[M(D') \in S] \times e^{\in} + \delta。\tag{9}$$

式中:Pr 为算法的输出概率,$M(D)$、$M(D')$分别代表保护机制 M 在数据集 D、D' 上的输出,δ 为失败的概率,$\in$ 为隐私预算,当 $\delta=0$ 时,差分隐私的性能最好。此外,还可用 $\ln \dfrac{Pr[M(D)\in S]}{Pr[M(D')\in S]}$ 的值表示隐私损失,其中 $\ln$ 表示自然对数运算。

隐私保护技术是保证联邦学习模型安全可靠运行的基础,近年来国内外的相关研究已取得了明显的进步,如表 3 所示。

表 3　隐私保护技术研究进展

技术类别	作者	主要创新点	优缺点
安全多方计算	MOHASSE 等[54]	隐私保护线性回归协议	扩展性强、高效快速;通信成本大、无法有效保证模型精度
	KILBERTUS 等[55]	模型公平认证、训练、验证	提高模型训练质量、有利于用户对私有敏感数据的控制;模型精度上有一定的损失、训练时间长、受多种敏感属性影响较大
	BYRD 等[56]	隐私保护开源平台	能很好解决用户端数据质量不平衡问题、可模拟用户端通信延迟;无法保证潜在的不诚实端给模型造成的不利影响
	KANAGAVELU 等[57]	两阶段安全多方计算	扩展性强、减少数据交互量、保证模型精度;模型训练时间长、模型复杂度高、未考虑不诚实第三方或敌手
	FENG 等[58]	梯度增强	计算和通信成本较低、在大型数据集上精度较高;扩展性差、稀松数据集上性能较差、模型训练时间长
		网络数据分析(Network Data Analytics, NWDA)框架+安全多方计算	隐私保护性强、方案容易部署;未考虑底层通信开销、数据量增加使得网络不可靠、未考虑计算成本

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

续表 3

同态加密	WADE 等[60]	分布式同态加密方案	鲁棒性强、抵抗攻击性强、能有效降低通信以及计算成本；模型复杂度高
	MA 等[61]	多密钥同态加密协议	保证了模型在诚实且好奇环境下的机密性、计算成本较低、保证模型精度；模型复杂度高、局部训练周期长
	YANG 等[62]	基于 FPGA 的同态加密框架	最大化整体吞吐量、计算效率高；对于非线性模型的有效性还需进一步验证、模型复杂度高
	ZHU 等[63]	基于阈值的秘密共享技术	显著减少计算和通信成本、编码简单；编码精度受安全级别的限制、引入三梯度值量化使得模型复杂高、收敛速度慢
	SONG 等[64]	无监督域自适应联邦算法	在半诚实的中心服务器和恶意第三方的环境下能保证安全性、显著提高目标精度；未能有效权衡通信开销和模型收敛性、模型计算效率还有待提高
差分隐私	TRIASTCYN 等[65]	贝叶斯差分隐私	模型准确性提高 10%、较少的噪音达到隐私保证效果；模型可解释性差、未考虑半诚实的中心服务器和恶意第三方
	SUN 等[66]	局部差分隐私聚合机制	提升模型训练性能、通信轮次少；模型精度无法保证、模型复杂度高、未考虑半诚实的中心服务器和恶意第三方
	NASERI 等[67]	局部和中央差异隐私机制	防御攻击性强、有效降低攻击精度；模型可解释性差、效用低、隐私预算成本高、模型复杂度高
	KIM 等[68]	FedSGD＋差分隐私机制	所需噪声方差小、效用高、传输速率低；未考虑半诚实的中心服务器和恶意第三方、需权衡计算和通信成本之间的有效性
	XIN 等[69]	基于差分隐私生成对抗网络模型	生成高质量的合成数据、模型性能高；未考虑半诚实的中心服务器和恶意第三方、计算和通信成本之间的有效性需进一步验证

可以看出，当前的隐私保护技术主要是通过加密或添加噪音的方法，如安全多方计算、同态加密以及差分隐私等，来保证用户端和中央服务器之间的安全通信，但无法有效权衡模型精度和计算成本[54-55,58-59,64,66-69]，且无法保证用户端诚实与否[56,65-66,68-69]，对整个联邦学习模型训练造成潜在的威胁。而模型复杂度的提高[60-63,66-67]，也不利于其实际应用部署。其次是现有隐私保护技术的单一性在一定程度上限制了联邦学习效能的发挥，而文献[58]的方案不失为一个好的参考方向，即利用多种隐私保护技术融合，为用户提供更强大的隐私安全保证。

3.2 通信效率

通信从广义上指的是需要信息的双方或多方在不违背各自意愿的情况下采用任意方法、任意媒质，将信息从某方准确安全地传送到另一方。而在联邦学习模型的每一轮训练过程中，中央服务器都需聚合、发送每一个参与方的模型参数。因此，随着参与方数量和迭代轮次的增加，将导致巨大的通信开销。此外，联邦学习还因其节点之间的不确定性，导致服务器与各参与方节点之间的通信成本往往高于传统的分布式机器学习。目前，已有许多学者就如何降低其通信成本进行了研究。

联邦平均[20]作为主流的聚合方法，其思想是将用户本地局部随机梯度(Stochastic Gradient Descent，SGD)和中心服务器结合，在不平衡和非独立同分布(Non-Identically and Independently Distributed，Non-IID)数据方面具有鲁棒性，适用于参与者目标函数相对于有限个样本误差累加形式的函数$\min_{w\in R^d} f(w)$，即

$$f(w)=\frac{1}{n}\sum_{i=1}^{n}f_i(w)=\frac{1}{n}\sum_{i=1}^{n}l(x_i,y_i,w_i)。\tag{10}$$

联邦平均是建立在 K 个用户端参与的基础上，其算法的目标函数定义如下：

$$f(w)=\frac{n_k}{n}\sum_{k=1}^{K}F_k(w),$$
$$F_k(w)=\frac{1}{n_k}\sum_{i\in P_k}f_i(w)。\tag{11}$$

式(10)和式(11)中：P_k 为第 k 个用户拥有的本地训练样本，K 为设备总量，n_k 为样本数且 $n_k=|P_k$

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

|,$F_k(w)$为第 k 个设备的本地目标函数,P_k 是第 k 个客户端的本地数据集,n 是所有用户端数据量总和,n_k 是第 k 个客户端数据量,$f_i(w)=l(x_i,y_i,w_i)$是具有参数 w 的模型对数据集 P_k 中的实例 (x_i,y_i)产生的损失函数。

采用联邦平均训练后的模型,得到一个优于各用户端局部的损失函数,其算法流程如下。

联邦平均算法:设 K 个用户端,B 为本地小批量数据集大小,E 为以每一次训练完本地所有数据为单位的总次数,η 为学习率。

服务器执行:

初始化模型参数 w_0

对于每一个全局模型更新轮次 i=1,2,3,…,do

确定随机选取 m←max(C·K,1)个参与方

m 个客户端随机集合 S_i

对于每一个参与方 $k\in S_i$,并行 do

w_{i+1}^k←参与方模型参数更新(k,w_i)

对模型参数聚合平均 $w_{i+1}\leftarrow\sum_{k=1}^{K}\frac{n_k}{n}w_{i+1}^k$

参与方更新:

将数据集 P_k 分成批量大小为 B 子数据集

对每个本地训练集遍历的次数 t 从 1 到 E do

对于每一个批次 $b\in B$ do

更新模型参数 $w\leftarrow w-\eta\nabla\zeta(\omega;b)$

将模型参数 w 返回服务器

为减少联邦平均给模型带来的不利影响,WANG 等[70]提出了联邦匹配平均技术,其在模型收敛性方面明显优于联邦平均,能有效利用已训练好的局部模型,减少通信负担;PRANEETH 等[71]提出了随机控制平均算法,用以纠正基于联邦平均在处理 Non-IID 数据时产生“客户漂移”的现象,并能降低用户因采样方差降低所带来的损失,利用参与者之间的相似性减少通信成本;YE 等[72]提出了一种边缘联邦学习,通过对设备端输出信息进行量化,分离本地模型训练,提高计算效率,降低通信成本。文献[70-72]的方法虽可减轻通信负担,但无法保证模型精度。为此,DANIEL 等[73]提出一种新算法——FetchSGD,用以克服用户端因其设备稀松参与面临的通信瓶颈和收敛问题,在保证模型精度的前提下,通过压缩梯度降低通信成本;类似的,KONEN 等[74]通过结构化更新和草图更新两种方法,将完整的模型压缩更新后发送到服务器聚合,结果所用方法表明能有效降低通信开销;HAMER 等[75]提出了 FedBoost 算法,训练一组预先训练好的机器学习模型参与到每一轮模型训练过程中,并在 100 个基础预测器中随机选取 T 个权重,更新后发送给服务器端用于更新这 100 个权重。与梯度压缩不同的是,该方法不仅降低了服务器与用户端之间的通信成本,还证明了其在标准检验风险以及不可知风险最小化任务中的最优性。文献[73-75]在模型精度以及通信方面具有明显优势,但因其模型复杂程度的增加,会给其实际部署带来不利影响。

3.3　异构性

异构是指由不同的元素或部分组成,不同领域对异构的解释也不尽相同。在机器学习领域,因联邦学习独特的模型训练方式,即通过分布式训练用户本地数据来获得一个高质量的全局模型,而无法捕捉到用户端本地设备信息,使得联邦学习面临异构性挑战:①用户端设备在不同分布式网络环境下,生成和收集的往往是 Non-IID 数据,导致统计异构性;②用户端因其设备存储、硬件条件(CPU、内存)、电源的不同、网络连接(3G、4G、5G、WiFi)等方面的差异而导致的系统异构性(如设备异构性、模型异构性)。这在一定程度上导致推理或分类性能有所下降,不利于联邦学习整体策略的制定。为此,针对异构性问题,已有诸多学者就其应对技术方案展开了相关研究,如表 4 所示。

表 4　异构性问题的应对技术方案

解决问题属性	作者	主要创新点	对比基准	优缺点
统计异构性	MILLS 等[76]	分布式 Adam 优化方法+压缩技术	联邦平均	减少通信次数和上传参数量、收敛速度快;增加额外成本、每轮训练时间长
	XIANG 等[77]	建立了收敛性理论保证	联邦平均	允许部分设备参与、权衡了通信效率和收敛速度;在非平衡数据上还需验证其有效性
	WANG 等[78]	FAVOR 框架、深度 Q 学习机制、模型压缩	联邦平均	加快收敛速度、有效降低通信轮数、允许部分设备参与、平衡 Non-IID 数据偏差;模型复杂度高、增加额外存储成本

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

续表 4

统计异构性	ZHAO 等[79]	创建一个全局共享数据子集	联邦平均	有效提高模型准确率；未考虑设备选择问题
	LIU 等[80]	知识迁移＋算法融合	—	提高学习效率和准确性、可扩展性强、提高训练速度、允许同步或异步；忽略一些其他客观因素（如交通信号）对最终模型的影响、未考虑通信成本问题
	ARIVAZHAGAN 等[81]	FedPer 框架	联邦平均	提高个性化建模中的有效性；全局模型参数聚合轮次增加导致模型性能不稳定、未考虑设备选择以及通信成本问题
设备异构性	LIU 等[82]	用户端—边缘端—云端分层联邦学习系统	基于云的联邦学习	减少模型训练时间以及终端设备的能量消耗、显著减少通信成本；模型可解释性差、未考虑设备选择问题
	XIE 等[83]	异步联邦优化算法	联邦平均	控制收敛速度和方差减少之间的平衡、提高了吞吐量；用户端设备延迟时间长导致模型收敛速度较慢、模型复杂度高
	HANZELY 等[84]	全局和局部模型混合	联邦平均＋SGD	允许部分设备参与、能较好处理异构数据；通信成本高、模型复杂度高、其推广有效性还需进一步验证
	WANG 等[85]	深度强化学习＋联邦学习	深度强化学习	减少上传模型参数量、能较好的解决终端异构性问题、允许部分设备参与；隐私安全还有待验证、增加了额外计算成本
模型异构性	JIANG 等[86]	元学习	联邦平均	模型精度收敛性显著提升、泛化性能好；个性化性能不稳定、模型可解释性差、通信成本高
	SMITH 等[87]	多任务学习	CoCoA 框架	能有效处理用户端设备容错和掉队现象、降低通信成本；不适用于非凸深度学习模型、模型复杂度高、增加额外的本地计算成本
	DINH[88]	个性化联邦学习算法—pFedMe	联邦平均＋Per-FedAvg	收敛速度快、局部精度高、可伸缩性强；未考虑设备选择问题、未能权衡模型性能、计算以及通信成本之间的有效性、模型复杂度高
	WU 等[89]	云端—边缘端个性化联邦学习框架—PerFit	传统的联邦学习	可部署个性化模型、提高单个设备的计算能力、可灵活地与多种个性化联邦方法集成；模型性能有所下降、模型复杂度高、未能有效权衡通信成本和模型性能
	LI 等[90]	知识精馏	不协作方式	允许参与者独立设计其模型、局部模型性能显著提高；无法保证隐私安全、通信成本较高、模型复杂度高

针对用户端的统计、设备、模型异构性问题，现有的一些技术能为其提供较好的解决方案，并取得了一定的成效，如平衡 Non-IID 数据偏差[78]、允许部分设备参与[84]、定制个性化联邦学习模型[89]等。但在通信成本和模型性能方面无法得到有效权衡[76,80-81,84,86,89-90]，这使得其方案在实际部署中的有效性仍需进一步验证。而模型复杂度的增加[78,83,87-90]以及存储、计算等额外成本的增多[78,85,87-88]，也给模型部署带来了极大的挑战。此外，在复杂的物联网环境下，当有大量用户端设备参与时，可能会出现某些用户端设备网络延迟或掉线等情况，而文献[79,81-82,88]等并未考虑用户端设备选择问题。因此，文献[77-78,84,87]更符合实际联邦环境设置。

3.4 激励机制

激励机制是指通过特定的方法与管理体系，将员工对组织及工作的承诺最大化。激励机制是所有经济活动的核心，无论对于个人决策还是在更大的制度结构内的合作和竞争[30]。由于联邦学习模型训练涉及多方参与，且参与方之间在数据质量方面

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

的不平衡性,导致用户不愿参与或使其参与到联邦学习中处于不公平的地位。但目前的研究主要集中在改善联邦学习模型性能上,忽视了用户加入联邦学习的激励机制。因此,如何使用户持续参与到联邦学习中,在最大化联邦学习可持续经营的同时最小化用户之间的不公平性,是保证联邦学习被广泛推广与应用的关键。

利用博弈论设计激励机制已展开诸多研究,如 KHAN 等[91]提出一种 Stackelberg 博弈的方法,可使参与用户有策略的设置局部迭代次数,以最大化其效用,结果表明了该方法在模拟中心服务器和边缘设备端之间交互建模的有效性;HU 等[92]采用两阶段 Stackelberg 博弈的方法,通过解决 Stackelberg 均衡,得到服务器和用户之间效用最大化策略;ZHAN 等[93]分析了 Stackelberg 博弈中 Stackelberg 均衡和 Nash 均衡两个阶段的唯一性,有效解决了激励机制是如何影响中心服务器的效用问题,并提出了基于 DRL 的激励机制,来解决非共享信息面临的独特挑战和联邦学习中贡献评估困难等问题。此外,可根据驱动方式的不同,有如表 5 所示的一些联邦学习激励机制方案设计。

表 5　不同驱动方式下的联邦学习激励机制方案设计

驱动方式	作者	主要创新点	优缺点
基于用户贡献驱动	ZHANG 等[94]	分层公平联邦学习框架	根据用户数据的贡献量给予相应的奖励、灵活性高;隐私安全无法保证、训练时间长、未考虑异构终端
	WANG 等[95]	删除方法+Shapley 值	适用横向和纵向联邦学习、能合理解释多个参与者的贡献;计算复杂度高
	LIU 等[96]	贡献评价机制+注意机制	能计算出每个用户端对服务器的贡献、计算复杂度较低;适用于特定时间的用户端评价、未考虑隐私安全
	SONG 等[97]	定义贡献指数(CI)	合理分配联邦模型所获得的利润、有效逼近准确的贡献指数、训练时间短;仅适用横向联邦学习
	ZENG 等[98]	多维激励框架—FMore	模型轻量级且具有兼容性、模型性能高、模型训练轮次有效减少;未考虑外部或内部攻击、增加额外成本
基于用户声誉驱动	ZHAO 等[99]	基于区块链的声誉系统+归一化技术	保证隐私安全、实现模型可追踪、有奖惩机制;系统高度依赖用户的培训结果、增加额外的存储负担、模型复杂度高、通信成本高
	REHMAN 等[100]	声誉感知细粒度联邦学习+边缘计算	保证隐私安全、灵活性高、保证用户提供数据的真实性、可追溯性、有奖惩机制;模型复杂度高、计算和通信成本高
	KANG 等[101]	基于区块链的可靠联邦学习声誉系统	智能选择可靠的用户、模型性能好、保证隐私安全、模型精度高;模型复杂度高、计算复杂、在 Non-IID 环境下具有局限性、未能有效权衡通信成本和模型性能
	LYU 等[102]	公平协作联邦学习框架	实现了较高的公平性、保证模型精度、参与者将获得与其贡献相匹配的绩效模型、自动识别和隔离“搭便车者”;未考虑鲁棒性、未能权衡通信成本和模型性能
基于用户资源配置驱动	SARIKAY 等[103]	Stackelberg 博弈模型	减少模型收敛时间、允许用户提供多样化数据进行模型训练;未考虑设备掉队问题、受 CPU 功率限制
	KHAN 等[91]	基于 Stackelberg 博弈	用户可以策略性地设置本地迭代的次数、最大化用户效用、最小化计算和通信代价;受 CPU 功率限制、本地模型训练迭代次数多
	PANDEY 等[104]	众包机制	使每个用户端利益最大化、保证局部模型精度、提高参与用户之间的公平性;模型复杂度高、无法保证全局模型精度
	LE 等[105]	拍卖机制	保证用户提供数据的真实性、模型性能好;模型复杂度高、未能有效权衡通信成本和模型性能

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

针对目前基于不同驱动方式的激励机制方案设计，如基于用户贡献驱动、基于用户声誉驱动以及基于用户资源配置驱动，虽能保证用户奖励合理分配[94,97,102]，但未能有效权衡模型性能和计算成本[97,101-102]，这在一定程度上降低了其方案的实用性；其次是激励机制方案设计缺乏隐私安全保证，如文献[94-96,98]。而文献[99-101]虽能更好地保证用户隐私安全，但其模型复杂度高，也给模型部署带来了一定的局限性。此外，如文献[99-100]，其评分机制过于主观，缺乏质量评价方案，容易受到恶意评分者的影响，而文献[101]则是通过多权重主观逻辑模型生成其综合声誉价值，能较好地消除恶意用户的影响，从而提高模型的可靠性、公平性。

4 联邦学习的应用

近年来涌现的诸多联邦学习应用平台和框架，大大加快了联邦学习的落地应用进程。同时，随着联邦学习的兴起和成熟，其在各国政府重点关注的智能制造、医疗以及教育等数据敏感领域具有广泛的应用前景，并取得了可观的成效。

4.1 应用平台和框架

联邦学习经过几年的迅猛发展，技术和应用逐渐走向成熟，涌现了众多的平台和框架，如腾讯安全联邦学习应用服务平台(FLAS)、基于百度飞桨(PaddlePaddle)的开源联邦学习框架 PaddleFL、微众银行的开源项目联邦学习框架(Federated AI Technology Enabler，FATE)、谷歌发布的 Tensorflow Federated 框架、富数科技旗下的安全计算产品—富数多方安全计算平台(FMPC)，以及由人工智能平台 OpenMind 领导首次实现的隐私保护深度学习通用框架 PySyft 等，各平台和框架的优势与不足如表 6 所示。

表 6 各联邦学习平台和框架优缺点

框架名称	优势	缺点	是否开源	应用场景
FLAS	含有多种加密算法、大数据分析能力强、多种联合建模方式	仅支持纵向和横向联邦学习，不支持联邦迁移学习	是	金融、营销、智能终端
PaddleFL	采用 MPC 方案实现联邦学习、适用于大规模的分布式联邦学习计算	仅支持纵向和横向联邦学习，不支持联邦迁移学习、系统复杂性高	是	金融风控、AI 医疗
FATE	覆盖横向、纵向、迁移联邦学习、样本安全匹配和切分、含有模型评估、模型预测、加密等算法、算法扩展相对较容易、支持多方部署、可扩展性强	环境配置复杂、操作程度较复杂、不同版本之间差异大、仅支持 python3、不支持 GPU 计算以及多个任务同时运行、缺少隐私保护技术集成库或工具箱	是	信贷风控，客户权益定价，监管科技等领域
Tensorflow Federated	支持各种算法和深度学习、编写代码较方便、支持 GPU 计算	仅支持横向联邦、调试困难、未开放多方联邦接口、大多局限于实验测试、缺少隐私保护技术集成库或工具箱	是	—
FMPC	通过密文训练联邦学习模型时可降低模型误差、具备支持算法众多、收敛速度快、部署灵活、建模速度快	输出日志信息较少、可扩展性较差、算法以批处理为主、目前未开源	否	金融风控、营销
PySyft	PySyft 相对容易上手、集成了安全多方计算和差异隐私	不同版本之间有较大差异、仅支持横向联邦学习、异步训练消耗大量时间用于节点之间的通信	是	—

针对上述联邦学习应用平台和框架，如 FLAS、PaddleFL、Tensorflow Federated、PySyft 等，并不支持联邦迁移学习，导致其实际应用部署时的局限性，相比之下，FATE 因其覆盖横向、纵向联邦学习以及联邦迁移学习，更符合企业数据信息资源共享的实际需求，但其版本之间的兼容性较差，且对实验环境配置有着严格的要求，不利于其框架的部署。其次，如 PaddleFL 系统复杂性高、FMPC 并未开源、PySyft 模型训练时间成本高以及 Tensorflow Federated 调试困难等缺点，不利于研究人员更好地

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

使用和开发。而 FATE 因其扩展性强、支持多方部署等优点,更有利于研究人员开展实验,但其操作复杂程度还需进一步降低。

4.2　在智能制造领域中的应用

随着《中国智能制造 2025》浪潮的推进,智能制造行业信息化进程大大加快,使得制造大数据呈现出爆炸式增长趋势[106-107]。近年来,各种新兴热点技术推动着智能制造行业的发展[108],如物联网技术[109-110]、大数据技术[111-112]、云计算技术[113-114]、人工智能算法[115]、区块链技术[116]等,虽有效解决了制造大数据中的信息提取、存储、传输以及计算问题,但无法完全保证数据共享过程中的安全性。此外,相关数据隐私技术因其技术本身的局限性、数据信息量的约束等因素,未能有效解决数据隐私保护问题。这在一定程度上阻碍了企业之间的数据共享,难以充分发挥数据潜在价值。

联邦学习在遵守规范框架的前提下,通过参与方协作构建模型而成为主流方案[25],在保证数据隐私安全的同时,实现多方数据共享,是一种创新的建模机制,随着联邦学习在隐私方面取得的成就,其在智能制造领域的应用是合乎逻辑的。只有当联邦学习被应用到智能制造领域,才能利用这些分散的数据获得无限的收益。

针对目前联邦学习在智能制造领域的研究鲜有开展,为此,结合联邦学习在数据共享方面具有明显的优势,本文构建出如图 5 所示的基于工业机器人、智能汽车和无人机等行业的联邦学习应用框架。首先对企业数据 1、企业数据 2 和企业数据 3(如制造数据、生产数据等)按其数据的特征/样本对齐划分,企业端从云端服务器下载全局初始模型进行本地模型训练;其次采用边缘计算技术,对各企业本地模型进行分割后,加密上传给边缘端进行模型训练;最后云端服务器聚合来自边缘端训练后加密上传的模型参数,用于新一轮的更新。在保证企业数据隐私安全的同时,进一步为企业的智能化升级提供技术支撑与智能决策。

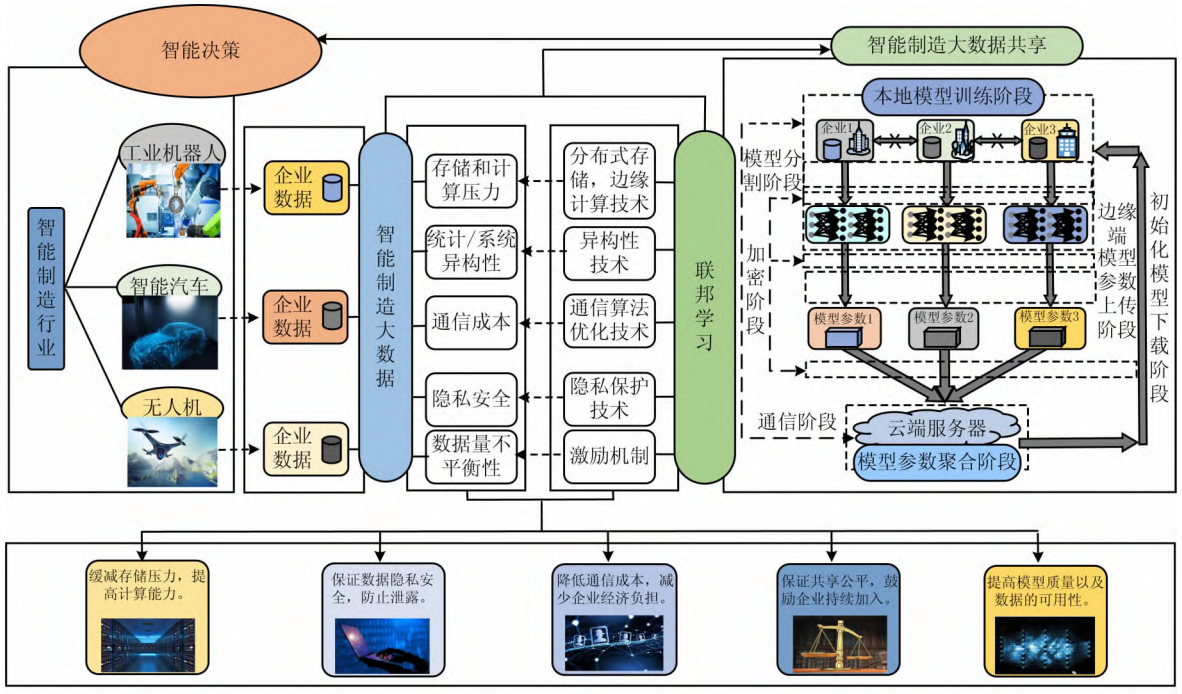


图5　基于工业机器人、智能汽车和无人机等行业的联邦学习应用框架

4.3　在医疗领域中的应用

随着人工智能技术的发展,为减少人工成本和人为误差,诸多人工智能技术在医疗领域得到发展[117-118],但仍处于起步阶段。由于难以收集到全面描述患者的数据,从而无法准确诊断患者疾病。若采用传统的机器学习,数据和标签的不足将导致机器学习模型性能降低。联邦学习技术能够促进医疗机构之间的联合,如图 6 所示。首先,医院 1、医院 2、医院 3 从中央服务器下载初始化模型,进行本地模型加密(如同态加密)训练;其次医院 1、医院 2、医院 3 将其本地训练后的模型参数加密传输至中央服务器聚合,用于下一轮的更新。其中,在本地模型

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

训练阶段，对医院 1、医院 2、医院 3 进行本地数据（如基因诊断数据、药物开发数据以及电子健康记录等）对齐，通过引入医院 4 作为协作者，用以分发公钥、加密汇总梯度损失等。因此，各医疗机构在不交换或公开其原始数据的基础上，大大提高了其数据共享的隐私安全性，同时使得各参与方可协作训练一个共同的共享模型，使得该模型性能优于单一医疗机构上训练的模型。此外，联邦迁移学习技术在各医疗机构因样本差异性而导致模型欠佳问题上具有明显优势，在智能医疗系统中发挥着重要作用。

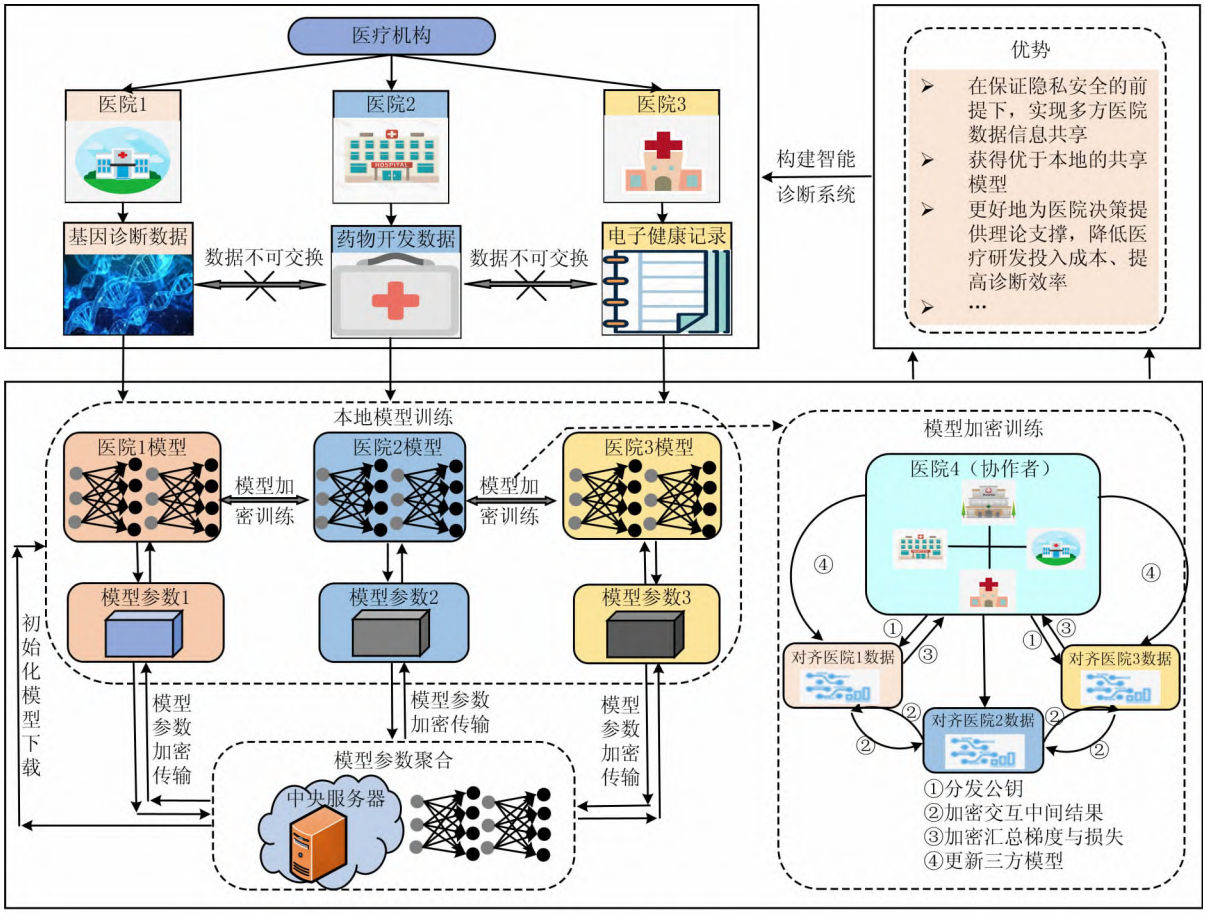


图6 联邦学习智能诊断

现阶段联邦学习与医疗领域结合的相关研究已有开展，如 BRISIMI 等[119]利用聚类原始对偶分解算法，通过解决各种数据源/用户中的电子健康记录数据，来预测心脏病相关患者的未来住院治疗概率；FEKI 等[120]提出一个协作式联邦学习框架，允许多个医疗机构使用深度学习从胸部 X 射线图像中筛选出 COVID-19，而无需共享患者数据；YAN 等[121]为解决医学图像数据中的跨客户端发生变异难题，首次提出了一种变异感知联邦学习（Variation-Aware Federated Learning，VAFL）框架，使用多源分散表观扩散系数（Apparent Diffusion Coefficient，ADC）图像数据对其进行评估，并取得了较好的稳定性。因此，随着联邦学习技术的发展，其在数据敏感性强的医疗领域显示出强大的应用潜力。

4.4 在教育领域中的应用

近年来，人工智能、大数据等技术在教育领域的研究已取得一定的进展，如 ZHANG 等[122]基于深度学习构建出一个适用于高等教育的智能教育系统框架，实现对学生的知识学习状况进行跟踪；LIU 等[123]提出一种基于人工智能神经网络误差反向传播算法和压力测试的方法，来分析教师的教学态度、教学内容、教学方法等对大学生对知识的掌握和能力建设的影响；STANDEN 等[124]采用多模式传感器数据与机器学习算法相结合的方法，来识别与学习相关的情感状态，继而确定学习内容的呈现方式，从而使学习者保持最佳的情感状态，并最大程度地提高其学习速度。这些技术虽加快了教育智能化进

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

程,但长期以来,教育工作者更期望能够建立一套跨学科的综合课程教学系统,而 STEM[125]、自适应电子学习[126]等系统缺少综合性学习体验,仅局限在单一或几个学科,不具全面性,无法针对学生学习能力和兴趣爱好等差异而实现定制化教育。

为此,联邦学习可实现教育资源的整合,构建一个覆盖性全面的初始模型,通过整合学习者模型、课程知识等,并拓展延伸以适应于其他学习者,实现定制化教育,如图 7 所示。针对学生 A、学生 B、学生 C 不同的兴趣爱好,教育机构利用联邦学习技术,基于学生端移动设备(如智能手机、Ipad 以及笔记本电脑)所存储的数据,协同构建一个通用学习计划模型。其一般流程是由各学生端从教育机构下载初始化通用学习计划模型,用于本地模型训练,但因学生端不同设备而导致的设备异构性问题,可通过引入用户端—边缘端—云端分层联邦学习系统,允许多个边缘服务器执行部分模型聚合[82],用以减少模型训练时间、通信成本以及学生端设备的能量消耗,其架构如图 7 右下图所示。学生端将其模型参数发送给边缘服务器进行部分聚合后,由边缘服务器发送给云端服务器聚合;其次由云端服务器将聚合后的模型参数分发给边缘端;最后由边缘器发送给学生端用于其本地更新。因此,学生端可根据其自身特长、需求以及兴趣等进行本地模型更新,训练出定制化、个性化学习指导模型。

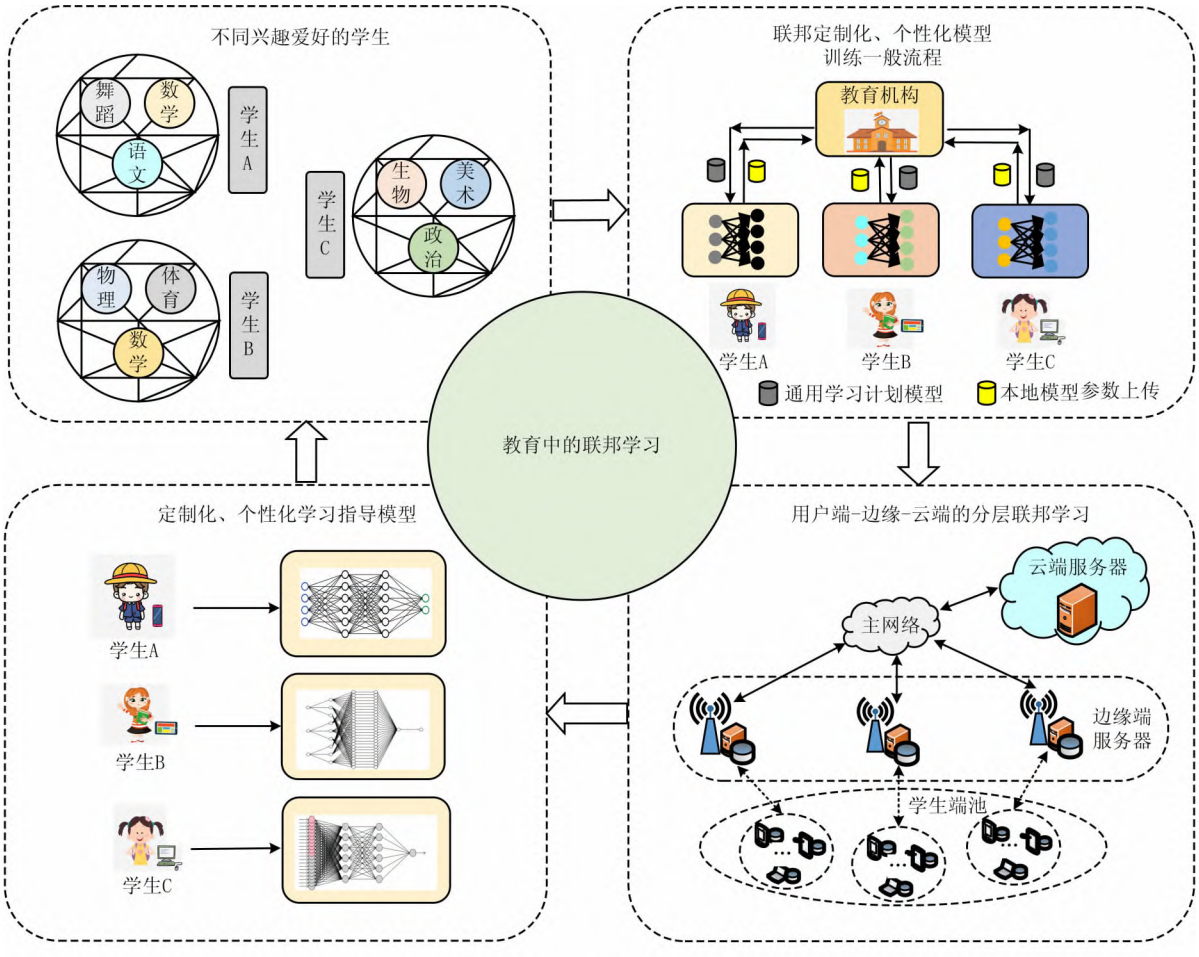


图7　联邦学习在教育中的应用

5　未来方向

综上所述,联邦学习旨在建立一个“数据隐私安全共同体”的训练模式,凭借其自身优势受到了许多研究人员的广泛关注并取得诸多成效。而联邦学习作为新兴的人工智能基础技术,在许多关键的开放性问题上仍还有待探索。因此,本章将对联邦学习的隐私保护、通信效率、异构性、激励机制以及应用等方面的未来研究方向和挑战进行简要的分析与总结。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

(1)权衡隐私保护和联邦学习系统性能

联邦学习通过分布式进行本地模型的训练,但在其模型训练过程中,用户的敏感隐私数据仍可能泄露给对手或第三方[57,65-66,68],而现有的解决方案,是在牺牲联邦学习模型性能的基础上来保证其隐私安全,同时还给服务器增加了计算压力[59,64,67]。因此,隐私作为联邦学习的一个关键因素,在实现联邦学习系统时,需更好地权衡其系统性能与隐私保护之间的合理性、有效性,重点是增强隐私和标准化每个需求的方法,如采用通用应用程序编程接口(Application Programming Interfaces, APIs)的方法来实现这种增强[24]。

(2)建立多服务器安全交互模式

通信效率问题是当前众多学者热衷的研究热点,而现有的联邦学习模型训练都是基于一个服务器端和所有用户端进行模型参数交互,边缘计算的引入[82],虽在一定程度上缓解了中心服务器的通信及计算压力,但在大规模用户参与下,也会造成服务器端计算效率低下甚至瘫痪的情况。此外,为保证数据安全交互而采用加密或防御手段,给服务器增加巨大的通信负担,甚至会使训练节点通信延迟或失败。因此,可采取类似于对等网络结构联邦学习[42]模型训练方法,在多个服务器之间使用加密技术进行模型参数安全交互,其有效性虽有待验证,但仍值得深入研究。

(3)探索新的异步算法

联邦学习使得服务器在不接触用户原始数据的前提下,难以知晓用户数据是否混淆、标签是否正确、是否缺失类、特征和值[39]等异构程度,同时还可能出现掉队或容错的情形,这使得其模型性能出现较大的偏差。因此,异步联邦学习算法[83]可作为一种解决方案,更符合实际的联邦学习设置,也是使联邦学习具有可扩展性的一个重要因素。但为保证模型收敛性,同步联邦学习算法仍是当前常用的方法[81]。鉴于异步联邦学习的诸多优势,其算法创新仍是未来工作中应持续探索的方向,如考虑非凸损失函数在 Non-IID 环境中的收敛性[127]。

(4)保证激励机制方案设计的安全性

尽管目前已有许多学者在联邦学习的激励机制方案设计方面做了很多工作,并已取得一定成效[94,102],但他们并未考虑其中的一个关键问题,即激励机制设计方案的安全性[96,98]。若联邦学习模型训练过程中存在不诚实敌手或第三方,如用户利用较少的数据进行本地模型训练,造成本地模型训练提前中止,使得模型性能产生较大的偏差,增加用户数据隐私泄露风险。因此,有必要对恶意用户进行惩罚,从而降低他们作恶的概率,将是一个重要的方向[99]。

(5)提高模型可解释性

可解释性是指让人类理解或向人类解释的能力,而联邦学习独特的训练方式在一定程度上增加了模型的复杂度,不利于研究者更好地将数据、模型以及问题理解结合起来,无法对模型异常的产生原因进行定位和追踪,其内在暴露的安全隐患问题,对模型的可靠性和安全性造成一定的威胁[128]。因此,可利用局部可解释模型[129]、模型替代[130]等技术,从局部模型、全局模型等角度来提高模型可解释性,实现模型异常的可溯性,也是未来研究中的一大挑战。

(6)探索多技术融合方法

现有的诸多联邦学习技术在模型效果方面受限,即在模型精度、通信成本等单一或少数方面虽具有明显优势,却未能有效权衡联邦学习中隐私保护、异构性以及公平性等多方面因素,这使得诸多联邦学习模型方案缺乏实用性。因此,通过多技术融合,如区块链技术与安全多方计算结合[131]、安全多方计算与同态加密结合[58]等,来提高模型的泛化性、实用性。但就目前而言,由于技术之间的局限性,除算法创新难度大之外,保证多技术融合方法的可行性、有效性对研究者来说也是一个巨大的挑战。

(7)开发功能性完善的联邦学习应用平台和框架

当前已有的一些联邦学习应用平台和框架功能还不够完善,如 FLAS、PaddleFL 只支持横向和纵向联邦学习,而在实际应用中,大多企业因其数据之间的样本和特征并无交集,从而使得联邦迁移学习更具普适性;其次是 TensorFlow Federated、FATE 等联邦学习框架缺少隐私保护技术集成库或工具箱,如同态加密、差分隐私等。而 PySyft 虽集成了安全多方计算和差分隐私机制,但仅支持横向联邦学习,这在一定程度上使其实际应用部署受限,不利于联邦学习效能的充分发挥。尽管目前各联邦学习应用平台和框架具有一定的局限性,但利用其优势互补,开发出完善、高效的联邦学习应用平台和框架也是未来可践行的一个研究方向。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

6　结束语

本文重点介绍了联邦学习的隐私保护、通信效率、异构性以及激励机制 4 个方面的相关技术研究进展,并分析了各技术的优势与不足;对现有的联邦学习框架进行了对比分析,并提出了联邦学习在智能制造、医疗以及教育等领域的应用框架;最后为研究学者在联邦学习领域提供了一些未来可参考的研究方向。随着各企业之间数据孤岛问题日益严重,迫切需要新技术在保证数据隐私安全的前提下实现数据共享,从而使得各行业健康可持续发展。为此,联邦学习应运而生,给各企业之间数据共享提供了新的解决思路和方案,随着联邦学习的应用与发展,势必能在各行各业发挥其更大的价值。

参考文献:

[1] XIAO Y, LIU Q. Application of big data processing method in intelligent manufacturing[C]//Proceedings of International Conference on Mechatronics and Automation. Washington, D. C., USA: IEEE, 2019: 1895-1900.

[2] MAHIRI F, NAJOUA A, SOUDA S B. Data-driven sustainable smart manufacturing: A conceptual framework[C]//Proceedings of International Conference on Intelligent Systems and Computer Vision. Washington, D. C., USA: IEEE, 2020.

[3] NGUYEN G, DLUGOLINSKY S, BOBÁK M, et al. Machine learning and deep learning frameworks and libraries for large-scale data mining: A survey[J]. Artificial Intelligence Review, 2019, 52(1): 77-124.

[4] CHEN X J, JIANG B. Analysis of the application of machine learning algorithms in data mining[J]. Journal of Physics: Conference Series, 2020, 1550(3): 032039.

[5] BORGES F, PINTO A, RIBEIRO D, et al. An unsupervised method based on support vector machines and higher-order statistics for mechanical faults detection[J]. IEEE Latin America Transactions, 2020, 18(6): 1093-1101.

[6] MOHAN L, PANT J, SUYAL P, et al. Support vector machine accuracy improvement with classification[C]//Proceedings of the 12th International Conference on Computational Intelligence and Communication Networks. Washington, D. C., USA: IEEE, 2020.

[7] XIAO P. Information management of E-Commerce platform based on neural networks and fuzzy deep learning models[C]//Proceedings of International Conference on Smart Electronics and Communication. Washington, D. C., USA: IEEE, 2020.

[8] TIYAJAMORN P, LORPRASERTKUL P, ASSABUMRUNGRAT R, et al. Automatic trash classification using convolutional neural network machine learning[C]//Proceedings of the International Conference on Cybernetics and Intelligent Systems and IEEE Conference on Robotics, Automation and Mechatronics. Washington, D. C., USA: IEEE, 2019.

[9] CHOI H W, QURESHI N M F, SHIN D R. Analysis of electricity consumption at home using k-means clustering algorithm[C]//Proceedings of the 21st International Conference on Advanced Communication Technology. Washington, D. C., USA: IEEE, 2019.

[10] SOUABI S, RETBI A, IDRISSI M K, et al. A recommendation approach in social learning based on k-means clustering[C]//Proceedings of International Conference on Intelligent Systems and Computer Vision. Washington, D. C., USA: IEEE, 2020.

[11] NA T, KO J H, MUKHOPADHYAY S. Cascade adversarial machine learning regularized with a unified embedding[EB/OL]. [2020-10-11]. https://arxiv.org/pdf/1708.02582.pdf.

[12] SRAVANI B, BALA M M. Prediction of student performance using linear regression[C]//Proceedings of International Conference for Emerging Technology. Washington, D. C., USA: IEEE, 2020.

[13] RIBEIRO M, GROLINGER K, CAPRETZ M A M. MLaaS: Machine learning as a service[C]//Proceedings of the 14th International Conference on Machine Learning and Applications. Washington, D. C., USA: IEEE, 2016.

[14] WARING J, LINDVALL C, UMETON R. Automated machine learning: Review of the state-of-the-art and opportunities for healthcare[J]. Artificial Intelligence in Medicine, 2020, 104: 101822.

[15] LIN W Y, HU Y H, TSAI C F. Machine learning in financial crisis prediction: A survey[J]. IEEE Transactions on Systems, Man and Cybernetics Part C: Applications and Reviews, IEEE, 2012, 42(4): 421-436.

[16] GE Z Q, SONG Z H, DING S X, et al. Data mining and analytics in the process industry: The role of machine learning[J]. IEEE Access, 2017, 5: 20590-20616.

[17] YANG Geng, WANG Zhousheng. Survey on privacy protection in federal learning[J]. Journal of Nanjing University of Posts and Telecommunications: Natural Science, 2020, 40(5): 204-214(in Chinese).[杨　庚,王周生.联邦学习中的隐私保护研究进展[J].南京邮电大学学报:自然科学版,2020,40(5):204-214.]

[18] HUNT T, SONG C Z, SHOKRI R, et al. Chiron: Privacy-preserving machine learning as a service[EB/OL]. [2020-10-11]. https://arxiv.org/pdf/1803.05961.pdf.

[19] YANG Q, LIU Y, CHEN T J, et al. Federated machine learning: Concept and applications[J]. ACM Transactions on Intelligent Systems and Technology, 2019, 10(2): 1-19.

[20] MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[EB/OL]. [2020-10-11]. http://proceedings.mlr.press/v54/mcmahan17a/mcmahan17a.pdf.

[21] LUNDERVOLD A S, LUNDERVOLD A. An overview of

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

deep learning in medical imaging focusing on MRI[J]. Zeitschrift fur Medizinische Physik,2019,29(2):102-127.

[22] BRENDAN MCMAHAN H, RAMAGE D, TALWAR K, et al. Learning differentially private recurrent language models [EB/OL]. [2020-10-11]. https://arxiv.org/pdf/1710.06963.pdf.

[23] AHMED L, AHMAD K, SAID N, et al. Active learning based federated learning for waste and natural disaster image classification[J]. IEEE Access,2020,8:208518-208531.

[24] MOTHUKURI V, PARIZI R M, POURIYEH S, et al. A survey on security and privacy of federated learning[J]. Future Generation Computer Systems,2021,115:619-640.

[25] LI L, FAN Y X, TSE M, et al. A review of applications in federated learning[J]. Computers & Industrial Engineering, 2020,149:106854.

[26] KULKARNI V, KULKARNI M, PANT A. Survey of personalization techniques for federated learning[C]//Proceedings of the 4th World Conference on Smart Trends in Systems, Security and Sustainability. Washington, D. C., USA: IEEE,2020:794-797.

[27] MAMMEN P M. Federated learning:Opportunities and challenges [EB/OL]. [2020-10-11]. https://arxiv.org/pdf/2101.05428.pdf.

[28] ZHANG C, XIE Y, BAI H, et al. A survey on federated learning[J]. Knowledge-Based Systems,2021,216(1):106775.

[29] QIU Xinyuan, YE Zecong, CUI Xiaolong, et al. Summary of communication overhead of federated learning[J]. Journal of Computer Applications,2022,42(2):333-342(in Chinese). [邱鑫源,叶泽聪,崔翛龙,等. 联邦学习通信开销研究综述[J]. 计算机应用,2022,42(2):333-342.]

[30] ZHAN Y F, ZHANG J, HONG Z C, et al. A survey of incentive mechanism design for federated learning[J]. IEEE Transactions on Emerging Topics in Computing,2022,10(2): 1035-1044.

[31] XU J, GLICKSBERG B S, SU C, et al. Federated learning for healthcare informatics[J]. Journal of Healthcare Informatics Research,2021,5(1):1-19.

[32] BLANCO-JUSTICIA A, DOMINGO-FERRER J, MARTÍNEZ S, et al. Achieving security and privacy in federated learning systems:Survey, research challenges and future directions [J]. Engineering Applications of Artificial Intelligence,2021. 106:104468.

[33] LYU L J, YU H, MA X J, et al. Privacy and robustness in federated learning:Attacks and defenses[EB/OL]. [2021-05-11]. https://arxiv.org/pdf/2012.06337.pdf.

[34] CHEN Bing, CHENG Xiang, ZHANG Jiale, et al. Survey of security and privacy in federated learning[J]. Journal of Nanjing University of Aeronautics & Astronautics,2020,52(5): 675-684(in Chinese). [陈 兵,成 翔,张佳乐,等. 联邦学习安全与隐私保护综述[J]. 南京航空航天大学学报,2020,52(5):675-684.]

[35] LIM W Y B, LUONG N C, HOANG D T, et al. Federated learning in mobile edge networks: A comprehensive survey [J]. IEEE Communications Surveys & Tutorials, 2020, 22(3):2031-2063.

[36] KAISSIS G A, MAKOWSKI M R, RÜCKERT D, et al. Secure, privacy-preserving and federated machine learning in medical imaging[J]. Nature Machine Intelligence, 2020, 2(6):305-311.

[37] ZERKA F, BARAKAT S, WALSH S, et al. Systematic review of privacy-preserving distributed machine learning from federated databases in health care[J]. JCO Clinical Cancer Informatics,2020,4:184-200.

[38] YANG Q, FAN L X, YU H. Federated learning:Privacy and incentive[M]. Berlin, Germany:Springer-Verlag,2020.

[39] ALEDHARI M, RAZZAK R, PARIZI R M, et al. Federated learning: A survey on enabling technologies, protocols, and applications[J]. IEEE Access,2020,8:140699-140725.

[40] BRIGGS C, FAN Z, ANDRAS P. A review of privacy-preserving federated learning for the internet-of-things[M]// Federated Learning Systems. Berlin, Germany: Springer-Verlag,2021.

[41] LI T, SAHU A K, TALWALKAR A, et al. Federated learning: Challenges, methods, and future directions[J]. IEEE Signal Processing Magazine,2020,37(3):50-60.

[42] FENG S W, YU H. Multi-participant multi-class vertical federated learning[EB/OL]. [2021-05-11]. https://arxiv.org/pdf/2001.11154.pdf.

[43] KONEČNY J, MCMAHAN H B, RAMAGE D, et al. Federated optimization: Distributed machine learning for on-device intelligence[EB/OL]. [2021-05-11]. https://arxiv.org/pdf/1610.02527.pdf.

[44] GAO D S, JU C, WEI X G, et al. Hhhfl:Hierarchical heterogeneous horizontal federated learning for electroencephalography [EB/OL]. [2021-05-11]. https://arxiv.org/pdf/1909.05784.pdf.

[45] LIU Y, KANG Y, ZHANG X, et al. A communication efficient collaborative learning framework for distributed features [EB/OL]. [2021-05-11]. https://arxiv.org/pdf/1912.11187v4.pdf.

[46] SHARMA S, XING C P, LIU Y, et al. Secure and efficient federated transfer learning[EB/OL]. [2021-05-11]. https://arxiv.org/pdf/1910.13271.pdf.

[47] ZHAO Q, ZHAO C, CUI S J, et al. PrivateDL:Privacy-preserving collaborative deep learning against leakage from gradient sharing[J]. International Journal of Intelligent Systems, 2020,35(8):1262-1279.

[48] KAIROUZ P, BRENDAN MCMAHAN H, AVENT B, et al. Advances and open problems in federated learning[EB/OL]. [2021-05-11]. https://par.nsf.gov/servlets/purl/10250384.

[49] YAO A C. Protocols for secure computations[C]//Proceed-

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

ings of the 23rd Annual Symposium on Foundations of Computer Science. Washington, D. C., USA: IEEE, 1982.

[50] STEVENSON I. Data on data[J]. IEE Computing and Control Engineering, 2004, 15(3): 12-17.

[51] PAILLIER P. Public-key cryptosystems based on composite degree residuosity classes[C]//Proceedings of International Conference on the Theory and Applications of Cryptographic Techniques. Berlin: Germany: Springer-Verlag, 1999.

[52] DWORK C, MCSHERRY F, NISSIM K, et al. Calibrating noise to sensitivity in private data analysis[C]// Proceedings of the 3rd Cryptography Conference. Berlin: Germany: Springer-Verlag 2006.

[53] DWORK C. Differential privacy: A survey of results[C]// Proceedings of Theory and Applications of Models of Computation. Berlin, Germany: Spriinger-Verlag, 2008.

[54] MOHASSEL P, ZHANG Y P. SecureML: A system for scalable privacy-preserving machine learning[C]//Proceedings of IEEE Symposium on Security and Privacy. Washington, D. C., USA: IEEE, 2017.

[55] KILBERTUS N, GASCÓN A, KUSNER M, et al. Blind justice: Fairness with encrypted sensitive attributes[EB/OL]. [2021-05-11]. http://proceedings. mlr. press/v80/kilbertus18a/kilbertus18a. pdf.

[56] BYRD D, POLYCHRONIADOU A. Differentially private secure multi-party computation for federated learning in financial applications[C]//Proceedings of the 1st ACM International Conference on AI in Frinance. New York, N. Y., USA: ACM, 2020.

[57] KANAGAVELU R, LI Z X, SAMSUDIN J, et al. Two-phase multi-party computation enabled privacy-preserving federated learning[C]//Proceedings of the 20th IEEE/ACM International Symposium on Cluster, Cloud and Internet Computing. Washington, D. C., USA: IEEE, 2020.

[58] FENG Z, XIONG H Y, SONG C Y, et al. SecureGBM: Secure multi-party gradient boosting[C]//Proceedings of the IEEE International Conference on Big Data. Washington, D. C., USA: IEEE, 2019.

[59] ISAKSSON M, NORRMAN K. Secure federated learning in 5G mobile networks[C]//Proceedings of 2020-2020 IEEE Global Communications Conference. Washington, D. C., USA: IEEE, 2020.

[60] WADE M I, CHOUIKHA M, GILL T, et al. Distributed image encryption based on a homomorphic cryptographic approach[C]//Proceedings of the 10th Annual Ubiquitous Computing, Electronics and Mobile Communication Conference. Washington, D. C., USA: IEEE, 2019.

[61] MA J, NAAS S A, SIGG S, et al. Privacy-preserving federated learning based on multi-key homomorphic encryption[EB/OL]. [2021-05-11]. https://arxiv. org/pdf/2104. 06824. pdf.

[62] YANG Z X, HU S H, CHEN K. FPGA-based hardware accelerator of homomorphic encryption for efficient federated learning[EB/OL]. [2021-05-11]. https://arxiv. org/pdf/2007. 10560. pdf.

[63] ZHU H Y, WANG R, JIN Y C, et al. Distributed additive encryption and quantization for privacy preserving federated deep learning[J]. Neurocomputing, 2021, 463(C): 309-327.

[64] SONG L, MA C G, ZHANG G Y, et al. Privacy-preserving unsupervised domain adaptation in federated setting[J]. IEEE Access, 2020, 8: 143233-143240.

[65] TRIASTCYN A, FALTINGS B. Federated learning with Bayesian differential privacy[C]//Proceedings of the IEEE International Conference on Big Data (Big Data). Washington, D. C., USA: IEEE, 2019.

[66] SUN L, QIAN J, CHEN X, et al. LDP-FL: Practical private aggregation in federated learning with local differential privacy[EB/OL]. [2021-05-11]. https://arxiv. org/pdf/2007. 15789. pdf.

[67] NASERI M, HAYES J, DE CRISTOFARO E. Toward robustness and privacy in federated learning: Experimenting with local and central differential privacy[EB/OL]. [2021-05-11]. https://arxiv. org/pdf/2009. 03561. pdf.

[68] KIM M, GÜNLÜ O, SCHAEFER R F. Federated learning with local differential privacy: Trade-offs between privacy, utility, and communication[C]//Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing(ICASSP). Washington, D. C., USA: IEEE, 2021.

[69] XIN B Z, YANG W, GENG Y Y, et al. Private FL-GAN: Differential privacy synthetic data generation based on federated learning[C]//Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Washington, D. C., USA: IEEE, 2020.

[70] WANG H, YUROCHKIN M, SUN Y, et al. Federated learning with matched averaging[EB/OL]. [2021-05-11]. https://arxiv. org/pdf/2002. 06440. pdf.

[71] KARIMIREDDY S P, KALE S, MOHRI M, et al. SCAFFOLD: Stochastic controlled averaging for federated learning [EB/OL]. [2021-05-11]. http://proceedings. mlr. press/v119/karimireddy20a/karimireddy20a. pdf.

[72] YE Y, LI S, LIU F, et al. Edgefed: Optimized federated learning based on edge computing[J]. IEEE Access, 2020, 8: 209191-209198.

[73] ROTHCHILD D, PANDA A, ULLAH E, et al. FetchSGD: Communication-efficient federated learning with sketching [EB/OL]. [2021-05-11]. http://proceedings. mlr. press/v119/rothchild20a/rothchild20a. pdf.

[74] KONEČNY J, MCMAHAN H B, YU F X, et al. Federated learning: Strategies for improving communication efficiency [EB/OL]. [2021-05-11]. https://arxiv. org/pdf/1610. 05492. pdf.

[75] HAMER J, MOHRI M, SURESH A T. Fedboost: A communication-efficient algorithm for federated learning[EB/OL]. [2021-05-11]. http://proceedings. mlr. press/v119/ha-

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

mer20a/hamer20a.pdf.

[76] MILLS J, HU J, MIN G Y. Communication-efficient federated learning for wireless edge intelligence in IoT[J]. IEEE Internet of Things Journal,2020,7(7):5986-5994.

[77] LI X, HUANG K X, YANG W H, et al. On the convergence of FedAvg on Non-IID data[EB/OL]. [2021-05-11]. https://arxiv.org/pdf/1907.02189.pdf.

[78] WANG H, KAPLAN Z, NIU D, et al. Optimizing federated learning on Non-IID data with reinforcement learning[C]// Proceedings of the IEEE Conference on Computer Communications. Washington, D.C., USA: IEEE, 2020.

[79] ZHAO Y, LI M, LAI L Z, et al. Federated learning with Non-IID data [EB/OL]. (2018-01-02). [2021-03-15]. https://arxiv.org/pdf/1806.00582.pdf.

[80] LIU B Y, WANG L J, LIU M, et al. Federated imitation learning: A novel framework for cloud robotic systems with heterogeneous sensor data[J]. IEEE Robotics and Automation Letters, 2020, 5(2): 3509-3516.

[81] ARIVAZHAGAN M G, AGGARWAL V, SINGH A K, et al. Federated learning with personalization layers[EB/OL]. (2019-12-02). [2021-03-25]. https://arxiv.org/pdf/1912.00818.pdf.

[82] LIU L M, ZHANG J, SONG S H, et al. Client-edge-cloud hierarchical federated learning [C]//Proceedings of 2020 IEEE International Conference on Communications. Washington, D.C., USA: IEEE, 2020.

[83] XIE C, KOYEJO S, GUPTA I. Asynchronous federated optimization[EB/OL]. (2019-03-10)[2021-01-11]. https://arxiv.org/pdf/1903.03934.pdf.

[84] HANZELY F, RICHTÁRIK P. Federated learning of a mixture of global and local models[EB/OL]. (2020-02-10)[2021-02-01]. https://arxiv.org/pdf/2002.05516.pdf.

[85] WANG X F, HAN Y W, WANG C Y, et al. In-edge AI: Intelligentizing mobile edge computing, caching and communication by federated learning[J]. IEEE Network, 2019, 33(5): 156-165.

[86] JIANG Y H, KONEČNY J, RUSH K, et al. Improving federated learning personalization via model agnostic meta learning[EB/OL]. (2019-09-27)[2021-01-31]. https://arxiv.org/pdf/1909.12488.pdf.

[87] SMITH V, CHIANG C K, SANJABI M, et al. Federated multi-task learning[EB/OL]. (2017-05-30)[2021-02-16]. https://arxiv.org/pdf/1705.10467.pdf.

[88] DINH C T, TRAN N H, NGUYEN T D. Personalized federated learning with Moreau envelopes[EB/OL]. (2020-01-16)[2021-02-18]. https://arxiv.org/pdf/2006.08848.pdf.

[89] WU Q, HE K W, CHEN X. Personalized federated learning for intelligent IoT applications: A cloud-edge based framework[J]. IEEE Open Journal of the Computer Society, 2020, 1: 35-44.

[90] LI D L, WANG J P. FedMD: Heterogenous federated learning via model distillation[EB/OL]. (2019-10-08)[2021-03-03]. https://arxiv.org/pdf/1910.03581.pdf.

[91] KHAN L U, PANDEY S R, TRAN N H, et al. Federated learning for edge networks: Resource optimization and incentive mechanism[J]. IEEE Communications Magazine, 2020, 58(10): 88-93.

[92] HU R, GONG Y M. Trading data for learning: Incentive mechanism for on-device federated learning[C]//Proceedings of the IEEE Global Communications Conference. Washington, D.C., USA: IEEE, 2021.

[93] ZHAN Y F, LI P, QU Z H, et al. A learning-based incentive mechanism for federated learning[J]. IEEE, 2020, 7(7): 6360-6368.

[94] ZHANG J F, LI C, ROBLES-KELLY A, et al. Hierarchically fair federated learning[EB/OL]. (2020-04-22)[2021-01-03]. https://arxiv.org/pdf/2004.10386.pdf.

[95] WANG G, DANG C X Q, ZHOU Z Y. Measure contribution of participants in federated learning[C]//Proceedings of International Conference on Big Data. Washington, D.C., USA: IEEE, 2020.

[96] LIU B Y, YAN B J, ZHOU Y Z, et al. A real-time contribution measurement method for participants in federated learning[EB/OL]. (2021-02-11)[2021-03-03]. https://arxiv.org/pdf/2009.03510v1.pdf.

[97] SONG T S, TONG Y X, WEI S Y. Profit allocation for federated learning[C]//Proceedings of the IEEE International Conference on Big Data. Washington, D.C., IEEE, 2019.

[98] ZENG R F, ZHANG S X, WANG J Q, et al. FMore: An incentive scheme of multi-dimensional auction for federated learning in MEC[C]//Proceedings of the 40th International Conference on Distributed Computing Systems. Washington, D.C., USA: IEEE, 2020.

[99] ZHAO Y, ZHAO J, JIANG L S, et al. Privacy-preserving blockchain-based federated learning for IoT devices[J]. IEEE Internet of Things Journal, 2020, 8(3): 1817-1829.

[100] UR REHMAN M H, SALAH K, DAMIANI E, et al. Towards blockchain-based reputation-aware federated learning [C]//Proceedings of the IEEE Conference on Computer Communications Workshops. Washington, D.C., USA: IEEE, 2020.

[101] KANG J W, XIONG Z H, NIYATO D, et al. Reliable federated learning for mobile networks[J]. IEEE Wireless Communications, 2020, 27(2): 72-80.

[102] LYU L J, XU X Y, WANG Q, et al. Collaborative fairness in federated learning[J]. Lecture Notes in Computer Science, 2020, 12500: 189-204.

[103] SARIKAYA Y, ERCETIN O. Motivating workers in federated learning: A Stackelberg game perspective[J]. IEEE Networking Letters, 2020, 2(1): 23-27.

[104] PANDEY S R, TRAN N H, BENNIS M, et al. A crowdsourcing framework for on-device federated learning

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[J]. IEEE Transactions on Wireless Communications,2020,19(5):3241-3256.

[105] LE T H T, TRAN N H, TUN Y K, et al. An incentive mechanism for federated learning in wireless cellular network:An auction approach[J]. IEEE Transactions on Wireless Communications,2021,20(8):4874-4887.

[106] O'DONOVAN P, LEAHY K, BRUTON K, et al. An industrial big data pipeline for data-driven analytics maintenance applications in large-scale smart manufacturing facilities[J]. Journal of Big Data,2015,2(1):1-26.

[107] YIN S, KAYNAK O. Big data for modern industry:Challenges and trends[J]. Proceedings of the IEEE,2015,103(2):143-146.

[108] YAO Xifan, LIU Min, ZHANG Jianming, et al. The past, present and future of intelligent manufacturing from the perspective of artificial intelligence[J]. Computer Integrated Manufacturing Systems,2019,25(1):19-34(in chinese).[**姚锡凡,刘　敏,张剑铭,等.人工智能视角下的智能制造前世今生与未来[J].计算机集成制造系统**,2019,25(1):19-34.]

[109] ARORA N, KAUR P D. Augmenting banking and fintech with intelligent internet of things technology[C]//Proceedings of the 8th International Conference on Reliability, Infocom Technologies and Optimization(Trends and Future Directions). Washington, D.C.,USA:IEEE,2020.

[110] PAIOLA M, GEBAUER H. Internet of things technologies, digital servitization and business model innovation in BtoB manufacturing firms[J]. Industrial Marketing Management,2020,89:245-264.

[111] CHIEN C F, CHEN Y J, HAN Y T, et al. AI and big data analytics for wafer fab energy saving and chiller optimization to empower intelligent manufacturing[C]//Proceedings of e-Manufacturing & Design Collaboration Symposium (eMDC). Washington, D.C.,USA:IEEE,2018.

[112] WANG C, DU W B, ZHU Z X, et al. The real-time big data processing method based on LSTM or GRU for the smart job shop production process[J]. Journal of Algorithms & Computational Technology,2020,14:63-67.

[113] LIU P C. Application of cloud computing technology in metal exploration[C]//Proceedings of International Conference on Computer Engineering and Application. Washington, D.C.,USA:IEEE,2020.

[114] ABBASI A A, ABBASI A, SHAMSHIRBAND S, et al. Software-defined cloud computing:A systematic review on latest trends and developments[J]. IEEE Access,2019,7:93294-93314.

[115] WILAMOWSKI B M, WU B, KORNIAK J. Big data and deep learning[C]//Proceedings of the 20th Jubilee International Conference on Intelligent Engineering Systems (INES). Washington,D.C.,USA:IEEE,2016.

[116] CAO Xuelian, ZHANG Jianhui, LIU Bo. A Survey of blockchain security, privacy and performance issues[J]. Computer Integrated Manufacturing Systems,2021,27(7):2078-2094(in Chinese).[**曹雪莲,张建辉,刘　波.区块链安全、隐私与性能问题研究综述[J].计算机集成制造系统**,2021,27(7):2078-2094.]

[117] BI W L, HOSNY A, SCHABATH M B, et al. Artificial intelligence in cancer imaging:clinical challenges and applications[J]. CA:A Cancer Journal for Clinicians,2019,69(2):127-157.

[118] PESAPANE F, CODARI M, SARDANELLI F. Artificial intelligence in medical imaging:threat or opportunity?Radiologists again at the forefront of innovation in medicine[J]. European Radiology Experimental,2018,2(1):1-10.

[119] BRISIMI T S, CHEN R D, MELA T, et al. Federated learning of predictive models from federated electronic health records[J]. International Journal of Medical Informatics,2018,112:59-67.

[120] FEKI I, AMMAR S, KESSENTINI Y, et al. Federated learning for COVID-19 screening from chest X-ray images [J]. Applied Soft Computing,2021,106:107330.

[121] YAN Z Q, WICAKSANA J, WANG Z W, et al. Variation-aware federated learning with multi-source decentralized medical image data[J]. IEEE Journal of Biomedical and Health Informatics,2021,25(7):2615-2628.

[122] ZHANG X, CAO Z. A framework of an intelligent education system for higher education based on deep learning[J]. International Journal of Emerging Technologies in Learning (iJET),2021,16(7):233-248.

[123] LIU C, FENG Y, WANG Y. An innovative evaluation method for undergraduate education:an approach based on BP neural network and stress testing[J]. Studies in Higher Education,2022,47(1):212-228.

[124] STANDEN P J, BROWN D J, TAHERI M, et al. An evaluation of an adaptive learning system based on multimodal affect recognition for learners with intellectual disabilities [J]. British Journal of Educational Technology,2020,51(5):1748-1765.

[125] ALJALLAL M A, ALSHAMRANI S M. Developing and teaching science textbooks' content according to STEM education approach:The centralized educational system context [EB/OL]. [2021-03-13]. https://www.researchgate.net/profile/Mohammed-Aljallal-2/publication/339943382__Developing_and_Teaching_Science_Textbooks'_Content_According_to_STEM_Education_Approach_The_Centralized_Educational_System_Context/links/5e6e78dd458515e5557fa838/Developing-and-Teaching-Science-Textbooks-Content-According-to-STEM-Education-Approach-The-Centralized-Educational-System-Context.pdf.

[126] BOUSSAKSSOU M, HSSINA B, ERITTALI M. Towards an adaptive E-learning system based on Q-learning algorithm [J]. Procedia Computer Science,2020,170:1198-1203.

[127] CHEN J M, PAN X H, MONGA R, et al. Revisiting dis-

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

tributed synchronous SGD[EB/OL]. (2016-04-04)[2021-02-03]. https://arxiv.org/pdf/1604.00981.pdf.

[128] LIU Junxu, MENG Xiaofeng. Summary of research on privacy protection of machine learning[J]. Journal of Computer Research and Development, 2020, 57(2): 346-362(in Chinese).[刘俊旭,孟小峰. 机器学习的隐私保护研究综述[J]. 计算机研究与发展,2020,57(2):346-362.]

[129] KUMARAKULASINGHE N B, BLOMBERG T, LIU J T, et al. Evaluating local interpretable model-agnostic explanations on clinical machine learning classification models[C]// Proceedings of the 33rd International Symposium on Computer-Based Medical Systems. Washington, D. C., USA: IEEE, 2020.

[130] NA J, BAK J H, SAHINIDIS N V. Efficient Bayesian inference using adversarial machine learning and low-complexity surrogate models[J]. Computers and Chemical Engineering, 2021, 151: 107322.

[131] WENG J, WENG J, ZHANG J, et al. DeepChain: Auditable and privacy-preserving deep learning with blockchain-based incentive[J]. IEEE Transactions on Dependable and Secure Computing, 2021, 14(8): 2438-2455.

作者简介:

李少波(1973－),**男,湖南岳阳人,教授,博士,博士生导师,研究方向:制造信息系统、制造物联、制造大数据、计算智能等**,E-mail:lishaobo@gzu.edu.cn;

＋**杨　磊**(1997－),**男,贵州铜仁人,硕士研究生,研究方向,联邦学习,通讯作者**,E-mail:2501623651@qq.com;

李传江(1995－),**男,山西临汾人,博士研究生,研究方向:智能制造、小样本学习、元学习**,E-mail:chuanjiang_lj@163.com;

张安思(1991－),**男,贵州凯里人,讲师/校聘副教授,博士,硕士生导师,研究方向:制造大数据、智能制造、人工智能、故障诊断与健康管理**,E-mail:zhangas@gzu.edu.cn;

罗瑞士(1996－),**男,贵州贵阳人,硕士研究生,研究方向:智能制造、故障诊断**,E-mail:2433448309@qq.com。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net